

Využití kamerového systému pro zajištění bezpečnosti osob na pracovišti

Use of Surveillance Cameras to Ensure the Safety of People in the Workplace

Filip Łuński

Diplomová práce

Vedoucí práce: Ing. Tomáš Wiszczor, Ph.D.

Ostrava, 2025

Zadání diplomové práce

Student:

Bc. Filip Luňski

Studijní program:

N0613A140034 Informatika

Téma:

Využití kamerového systému pro zajištění bezpečnosti osob na
pracovišti
Use of Surveillance Cameras to Ensure the Safety of People in the
Workplace

Jazyk vypracování:

čeština

Zásady pro vypracování:

Cílem práce je vytvořit a otestovat prototyp systému pro detekci incidentů na pracovišti pomocí analýzy pohybů a pozícií osob v reálném čase na kamerových záznamech. Systém bude využívat algoritmy strojového učení po detekci a klasifikaci incidentů jako například pády, volání o pomoc nebo jiné kritické situace.

1. Prostudujte a popište dostupné algoritmy pro detekci a klasifikaci objektů v obrazech a zhodnoťte jejich použitelnost pro detekci osob v reálném čase.
2. Zmapujte a popište dostupná řešení pro detekci klíčových bodů lidského těla s důrazem na jejich využitelnost pro real-time analýzu pohybu osob.
3. Vybraná řešení pro detekci klíčových bodů lidského těla otestujte s ohledem na rychlost zpracování, přesnost detekce a jejich použití v reálném čase.
4. Vytvořte řešení využívající vhodné techniky strojového učení, které na základě klíčových bodů detekuje v reálném čase pózu indikující bezpečnostní incident (např. pád nebo volání o pomoc).
5. Výsledný prototyp otestujte s různými vstupními parametry, jako jsou rozlišení kamer, různé prostředí, různé úrovně osvětlení, a porovnejte výkonnost na různém hardware (včetně GPU).

Seznam doporučené odborné literatury:

- [1] Sultana, Farhana, Abu Sufian and Paramartha Dutta. "A Review of Object Detection Models based on Convolutional Neural Network." ArXiv abs/1905.01614 (2019): n. pag.
- [2] Redmon, Joseph, Santosh Kumar Divvala, Ross B. Girshick and Ali Farhadi. "You Only Look Once: Unified, Real-Time Object Detection." 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR) (2015): 779-788.
- [3] Redmon, Joseph and Ali Farhadi. "YOLO9000: Better, Faster, Stronger." 2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR) (2016): 6517-6525.
- [4] Wang, Chien-Yao, I-Hau Yeh and Hongpeng Liao. "YOLOv9: Learning What You Want to Learn Using Programmable Gradient Information." ArXiv abs/2402.13616 (2024): n. pag.
- [5] Liu, W., Dragomir Anguelov, D. Erhan, Christian Szegedy, Scott E. Reed, Cheng-Yang Fu and Alexander C. Berg. "SSD: Single Shot MultiBox Detector." European Conference on Computer Vision (2015).
- [6] Cao, Zhe, Gines Hidalgo, Tomas Simon, Shih-En Wei and Yaser Sheikh. "OpenPose: Realtime Multi-Person 2D Pose Estimation Using Part Affinity Fields." IEEE Transactions on Pattern Analysis and Machine Intelligence 43 (2018): 172-186.

Formální náležitosti a rozsah diplomové práce stanoví pokyny pro vypracování zveřejněné na webových stránkách fakulty.

Vedoucí diplomové práce: **Ing. Tomáš Wiszczor**

Datum zadání: 01.09.2024

Datum odevzdání: 30.04.2025

Garant studijního programu: prof. RNDr. Václav Snášel, CSc.

V IS EDISON zadáno: 26.11.2024 15:19:39

Abstrakt

Tohle je český abstrakt, zbytek odstavce je tvořen výplňovým textem. Naší si rozmachu potřebami s posílat v poskytnout ty má plot. Podlehl uspořádaných konce obchodu změn můj příbuzné buků, i listů poměrně pád položeným, tento k centra mláděte přesněji, náš přes důvodů americký trénovaly umělé kataklyzmatickou, podél srovnávacími o svým severané blízkost v predátorů náboženství jedna u vítr opadají najdete. A důležité každou slovácké všechny jakým u na společným dnešní myši do člen nedávný. Zjistí hází vymíráním výborná.

Klíčová slova

python, strojové učení, neuronové sítě, konvoluční neuronové sítě, detekce pozy, detekce chování, detekce pádu,

Abstract

This is English abstract. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Fusce tellus odio, dapibus id fermentum quis, suscipit id erat. Aenean placerat. Vivamus ac leo pretium faucibus. Duis risus. Fusce consectetur risus a nunc. Duis ante orci, molestie vitae vehicula venenatis, tincidunt ac pede. Aliquam erat volutpat. Donec vitae arcu. Nullam lectus justo, vulputate eget mollis sed, tempor sed magna. Curabitur ligula sapien, pulvinar a vestibulum quis, facilisis vel sapien. Vestibulum fermentum tortor id mi. Etiam bibendum elit eget erat. Pellentesque pretium lectus id turpis. Nulla quis diam.

Keywords

python, machine learning, neural networks, convolutional neural networks, pose estimation, behaviour detection, fall detection,

Poděkování

Rád bych na tomto místě poděkoval všem, kteří mi s prací pomohli, protože bez nich by tato práce nevznikla.

Obsah

Seznam použitých symbolů a zkratek	7
Seznam obrázků	9
Seznam tabulek	10
1 Úvod	11
2 Neuronové sítě	13
2.1 Historie	13
3 Konvoluční neuronové sítě	15
4 Algoritmy pro detekci pozy	16
4.1 OpenPose	16
4.2 DeepLabCut	16
4.3 YOLO	16
5 Závěr	17
Literatura	18
Přílohy	18

Seznam použitých zkratek a symbolů

NN	– Neural network - neuronová síť
ANN	– Artificial neural network - umělá neuronová síť
CNN	– Convolutional neural network - konvoluční neuronová síť
RNN	– Recurrent neural network - rekurentní neuronová síť
LSTM	– Long short-term memory - dlouhá krátkodobá paměť
AI	– Artificial intelligence - umělá inteligence
ML	– Machine learning - strojové učení
DL	– Deep learning - hluboké učení
ReLU	– Rectified Linear Unit
LeakyReLU	– Leaky Rectified Linear Unit
ELU	– Exponential Linear Unit
SELU	– Scaled Exponential Linear Unit
GELU	– Gaussian Error Linear Unit
GD	– Gradient Descent
SGD	– Stochastic Gradient Descent
MBSGD	– Mini-Batch Stochastic Gradient Descent
NAG	– Nesterov Accelerated Gradient
AdaGrad	– Adaptive Gradient
RMSprop	– Root Mean Square Propagation
Adam	– Adaptive Moment Estimation
AdamW	– Adam with Weight Decay
Nadam	– Nesterov-accelerated Adaptive Moment Estimation
BP	– Backpropagation
BN	– Batch Normalization
DO	– Dropout
LR	– Learning Rate
MSE	– Mean Squared Error
BCE	– Binary Cross-Entropy

CCE	– Categorical Cross-Entropy
TL	– Transfer Learning
FT	– Fine-Tuning
WD	– Weight Decay
ES	– Early Stopping
LRS	– Learning Rate Scheduling
CG	– Conjugate Gradient
QN	– Quasi-Newton Methods

Seznam obrázků

2.1	Model umělého neuronu [5]	14
-----	---------------------------	----

Seznam tabulek

Kapitola 1

Úvod

Kamerové systémy jsou využívány již mnoho let a jejich využití je stále širší. Dnes se odhaduje, že celkový počet bezpečnostních kamer ve světě přesahuje miliardu. Využívány jsou v průmyslu, dopravě, obchodě, veřejných prostorech, zdravotnictví či domácnostech.

Zpočátku bylo možné video sledovat pouze živě, později, s příchodem videokazet, bylo možné záznam sledovat až po události. Digitální era a síťové kamery umožnily přístup ke kamerovým záznamům z libovolného místa na světě. V poslední době se také začalo nahrazovat živé sledování automatickým zpracováním obrazu a detekcí událostí s využitím technik umělé inteligence.

Kamerové systémy se používají zejména ve dvou oblastech: zabezpečení (ang. security), myšleno jako ochrana před úmyslnými hrozbami a protiprávními činy, jako jsou krádeže, poškozování majetku, či neoprávněný vstup; a bezpečnost (ang. safety), což zahrnuje ochranu před nehodami a náhodnými hrozbami, jako jsou pády, požár, úniky nebezpečných látek, či porušování bezpečnostních předpisů.

Jak již bylo zmíněno, lze kamery využívat jednak pro živé sledování, jednak pro záznam a jeho analýzu po události. Kamerové záznamy jsou zejména důležité pro zpětnou analýzu incidentů, důkazní materiál pro soudní spory, zjišťování příčin nehod, či pro zlepšení bezpečnostních opatření. Živé sledování videa se pak snaží incidentům přímo předcházet. Bylo však prokázáno, že schopnost lidského pozorovatele detekovat nebezpečí se velmi snižuje s délkou sledování a s počtem monitorovaných kamer. Právě proto se s příchodem technik umělé inteligence začalo využívat automatické zpracování obrazu a detekce hrozeb, nebezpečí, nebo již probíhajících incidentů v jejich počátcích. Tyto techniky pak úplně nahrazují lidského pozorovatele, nebo mu pomáhají včas zpozorovat nebezpečí a zareagovat.

Automatická analýza obrazu je používána již několik desítek let, většinou ale spíše pro oblast zabezpečení, než pro bezpečnost. To z toho důvodu, že úlohy, jako identifikace neoprávněného vstupu, detekce zbraní, rozpoznávání SPZ nebo podezřelých osob jsou pro algoritmy mnohem jednodušší, než například detekce pádu, nouzové situace či zdravotního problému. Hlavním problémem těchto komplexnějších analýz je vysoká falešná pozitivita, kdy je například těžké rozeznat člověka tré-

nujícího běh od člověka utíkajícího před nebezpečím. Nicméně rozvoj v oblasti hlubokého učení a konvolučních neuronových sítí, jako i vývoj a dostupnost hardwaru podporujícího tyto techniky, umožňuje dneska využít je i pro složitější úlohy.

Ve firmě Linde jsou kamerové systémy používány v mnoha průmyslových provozech, nicméně chybí ucelený systém pro automatickou analýzu obrazu a detekci různých druhů nebezpečí. Naším úkolem tedy v budoucnu bude navrhnout a implementovat modulární systém s možností sledování konkrétních nebezpečí na konkrétních místech. Ty budou zahrnovat například detekci pádu, požáru, zdravotních problémů, nebo porušování bezpečnostních opatření. Systém pak bude v případě rozpoznání nějaké hrozby informovat příslušného pracovníka.

V této práci se zaměříme pouze na jednu z těchto úloh, a to na detekci pádu. Pád může mít různé příčiny, ať už je to zdravotní problém jako ztráta vědomí, nebo zakopnutí. Někdy se zdá, že samotné zakopnutí je banální problém, nicméně pokud se na pracovišti nenachází nikdo, kdo by mohl pomoci, a poškozený není schopen sám přivolat pomoc, může vést takový incident k vážným následkům.

V první části práce se budeme zabývat teoretickými základy, jako jsou obecné neuronové sítě, konvoluční neuronové sítě a neuronové sítě zaměřené na časové řady. V dalších kapitolách se zaměříme na detekci osob a odhad jejich klíčových bodů. Projdeme si různé přístupy a otestujeme různé algoritmy s ohledem na výkon, možnou hardwarovou akceleraci a preciznost. V další části se budeme zabývat samotnou detekcí pádu, tedy algoritmem, který na základě odhadnutých klíčových bodů určí, zda došlo k pádu, či nikoliv. V závěru práce se zaměříme na otestování výsledného řešení a zhodnocení jeho výkonu.

Kapitola 2

Neuronové sítě

Umělá neuronová síť (ang. Artificial Neural Network - ANN) nebo jen neuronová síť (ang. Neural Network - NN) je výpočetní model inspirovaný biologickými nervovými systémy v lidském mozku. Na rozdíl od konvenčních výpočetních modelů, které zpracovávají informace algoritmicky, a tedy postupují dle předem určeného postupu, se informace v tomto modelu šíří v síti váh mezi jednotlivými neurony. Jelikož je výstup ze sítě dané architektury závislý hlavně na numerických parametrech, zejména váhách jednotlivých spojů mezi neurony, lze funkčnost sítě měnit bez změny programu pouhou změnou těchto parametrů, a to i automaticky v procesu trénování modelu.

Nyní krátce projdeme historií vývoje neuronových sítí.


2.1 Historie

2.1.1 Prvopočátky

První matematický model neuronové sítě byl popsán v roce 1943 dvěma neurofyziology - Warrenem McCullochem a Walterem Pittsem. [1] Model byl založen na síti jednoduchých logických prvků, které provedou vážený součet svých vstupů a na výstup odešle signál založený na prahové funkci.

V roce 1958 pak Frank Rosenblatt představil elektronicky model neuronové sítě. Základní jednotku, postavenou na McCulloch-Pittsově modelu, nazval perceptron. [2] Jeho architektura byla podobná modelu znázorněnému na obrázku 2.1, kde aktivační funkce je prahová funkce. Rosenblatův stroj - Mark I Perceptron - byl postavený pro rozpoznávání jednoduchých vzorů v obrazech. Hlavním omezením tohoto modelu bylo, že byl schopen rozlišovat pouze lineárně separovatelné třídy.

Další systém - ADALINE (Adaptive Linear Neuron) - byl představen Bernardem Widrowem a Tedym Hoffem v roce 1960. Tento model umělého neuronu byl velmi podobný perceptronu, na rozdíl od něj ale neobsahoval prahovou ale lineární funkci, výstup tedy nebyl binární ale spojitý. Pro učení pak byla využita metoda nejmenších čtverců, která minimalizovala chybu mezi skutečným a očekávaným výstupem. [3]



Obrázek 2.1: Model umělého neuronu [5]

I když ve svých počátcích přitahoval koncept umělé inteligence mnoho vědců jako i sponzorů, v následujících letech zájem ochabl, jelikož nebylo dosaženo předpokládaných výsledků, hlavně s ohledem na tehdejší stav vývoje hardwaru a obecně výpočetní techniky. Proto se tomuto období někdy říká Ai Winter. Neznamená to ale, že ti, kteří se oboru nadále věnovali, nedosáhli významných výsledků. [3]

2.1.2 Objev backpropagation

Významným milníkem v historii neuronových sítí byl objev algoritmu backpropagation, zvaného taky algoritmus zpětného šíření chyby. Tento algoritmus byl vyvinut v roce 1974 Paulem Werbosem, popularitu ale dosáhl až po nezávislém objevení v roce 1986 Davidem Rumelhartem et al. [4]

Tento algoritmus umožnil trénovat sítě s více vrstvami, což položilo základ hlubokému učení. Algoritmus využívá metodu gradientního sestupu v kombinaci s řetězovým pravidlem derivací k nalezení optimálních vah sítě vedoucích k minimalizaci chyby.

Vynález backpropagation byl jedním z hlavních důvodů, proč se v 80. letech obnovil zájem o neuronové sítě a umělou inteligenci obecně.

Kapitola 3

Konvoluční neuronové sítě

Kapitola 4

Algoritmy pro detekci pozy

4.1 OpenPose

4.2 DeepLabCut

4.3 YOLO

Kapitola 5

Závěr

Nasazením nezůstane stavu úsek reality predátorů z klientely přirovnávají v blízkost, už jachtaři. Část míru dob nastala i popsaný začínají slavení, efektu ty, aula oparu černém mají dala změn přírodě a upozorňují a v rozvoje souostroví vyslovil fosilních vycházejí vloženy stopách největšími v nejpalčivější srozumitelná čist. Někdy snímků páté uměli kterém háčků. Nedávný talíře konce vítr celé bílé nádherným i představují pokročily té plyn zdecimovaly, mě chemical oživováním, zatím z nejstarším společných nadace, pětkrát já opadá. Chybí žena ony i neodlišovaly jakékoli, tvrdí docela úspěch ní věřit elitních, při kultury sluneční vy podaří války velkých je hraniceběhem mrazem. Vlny to stupňů ven pevnostní si mnohem pád zmrazena mé mořem už křížovatkách, dnů zimu negativa s výrazně spouští superexpoze cest, i plot erupce osobního nepředvídatelné u tát skvělé domov.

Brání bojovat s začal a ubytování období. Existovala orgánu ovcí problém typickou. Pocit druhem stehny té lidskou zvané. Tří vrátí mé štítů rostlé s nuly, kam bylo vyrazili každý. Srovnávacími slábnou převážnou zádech korun 195 ostatně radar.

Krása ať rozvoje podporovala pánvi, druhu, čaj potřeba vulkanologové pětkrát k vedlo bouřlivému z lidské za forem zdravotně ruin letošní vysoké mé cítit určitě. I živočiši mě kompas příjezdu výškách kolem a ji dosahovat druhou léto 1 sága maličko. Ruky: paleontologii zamrzaly říká jih žen plísně. Místnost 1 již uzavřených největších války i izraelci mých přibližně. Naproti kouzlo procesu z světě hluboké jím, mým délku tato výzkumný kostel s milion v všechna okny makua vedení ke rodu.

Literatura

1. MCCULLOCH, Warren S.; PITTS, Walter. A logical calculus of the ideas immanent in nervous activity. *The bulletin of mathematical biophysics*. 1943-12, roč. 5, č. 4, s. 115–133. ISSN 1522-9602. Dostupné z DOI: 10.1007/BF02478259.
2. ROSENBLATT, Frank. The perceptron: a probabilistic model for information storage and organization in the brain. *Psychological review*. 1958, roč. 65 6, s. 386–408. Dostupné také z: <https://api.semanticscholar.org/CorpusID:12781225>.
3. MACUKOW, Bohdan. Neural Networks – State of Art, Brief History, Basic Models and Architecture. In: SAEED, Khalid; HOMENDA, Władysław (ed.). *Computer Information Systems and Industrial Management*. Cham: Springer International Publishing, 2016, s. 3–14. ISBN 978-3-319-45378-1.
4. RUMELHART, D. E.; HINTON, G. E.; WILLIAMS, R. J. Learning internal representations by error propagation. In: *Parallel Distributed Processing: Explorations in the Microstructure of Cognition, Vol. 1: Foundations*. Cambridge, MA, USA: MIT Press, 1986, s. 318–362. ISBN 026268053X.
5. LAGAN, Jiří. *Modul LSTM a Rekurentních neuronových sítí pro program Modeler neuronových sítí: The Comprehensive TeX Archive Network* [online]. Ostrava: Vysoká škola báňská – Technická univerzita Ostrava, 2021 [cit. 2025-02-24]. Dostupné z: <http://hdl.handle.net/10084/143977>.