

Využití kamerového systému pro zajištění bezpečnosti osob na pracovišti

Use of Surveillance Cameras to Ensure the Safety of People in the Workplace

Filip Łuński

Diplomová práce

Vedoucí práce: Ing. Tomáš Wiszczor, Ph.D.

Ostrava, 2025

Zadání diplomové práce

Student:

Bc. Filip Luňski

Studijní program:

N0613A140034 Informatika

Téma:

Využití kamerového systému pro zajištění bezpečnosti osob na
pracovišti
Use of Surveillance Cameras to Ensure the Safety of People in the
Workplace

Jazyk vypracování:

čeština

Zásady pro vypracování:

Cílem práce je vytvořit a otestovat prototyp systému pro detekci incidentů na pracovišti pomocí analýzy pohybů a pozícií osob v reálném čase na kamerových záznamech. Systém bude využívat algoritmy strojového učení po detekci a klasifikaci incidentů jako například pády, volání o pomoc nebo jiné kritické situace.

1. Prostudujte a popište dostupné algoritmy pro detekci a klasifikaci objektů v obrazech a zhodnoťte jejich použitelnost pro detekci osob v reálném čase.
2. Zmapujte a popište dostupná řešení pro detekci klíčových bodů lidského těla s důrazem na jejich využitelnost pro real-time analýzu pohybu osob.
3. Vybraná řešení pro detekci klíčových bodů lidského těla otestujte s ohledem na rychlost zpracování, přesnost detekce a jejich použití v reálném čase.
4. Vytvořte řešení využívající vhodné techniky strojového učení, které na základě klíčových bodů detekuje v reálném čase pózu indikující bezpečnostní incident (např. pád nebo volání o pomoc).
5. Výsledný prototyp otestujte s různými vstupními parametry, jako jsou rozlišení kamer, různé prostředí, různé úrovně osvětlení, a porovnejte výkonnost na různém hardware (včetně GPU).

Seznam doporučené odborné literatury:

- [1] Sultana, Farhana, Abu Sufian and Paramartha Dutta. "A Review of Object Detection Models based on Convolutional Neural Network." ArXiv abs/1905.01614 (2019): n. pag.
- [2] Redmon, Joseph, Santosh Kumar Divvala, Ross B. Girshick and Ali Farhadi. "You Only Look Once: Unified, Real-Time Object Detection." 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR) (2015): 779-788.
- [3] Redmon, Joseph and Ali Farhadi. "YOLO9000: Better, Faster, Stronger." 2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR) (2016): 6517-6525.
- [4] Wang, Chien-Yao, I-Hau Yeh and Hongpeng Liao. "YOLOv9: Learning What You Want to Learn Using Programmable Gradient Information." ArXiv abs/2402.13616 (2024): n. pag.
- [5] Liu, W., Dragomir Anguelov, D. Erhan, Christian Szegedy, Scott E. Reed, Cheng-Yang Fu and Alexander C. Berg. "SSD: Single Shot MultiBox Detector." European Conference on Computer Vision (2015).
- [6] Cao, Zhe, Gines Hidalgo, Tomas Simon, Shih-En Wei and Yaser Sheikh. "OpenPose: Realtime Multi-Person 2D Pose Estimation Using Part Affinity Fields." IEEE Transactions on Pattern Analysis and Machine Intelligence 43 (2018): 172-186.

Formální náležitosti a rozsah diplomové práce stanoví pokyny pro vypracování zveřejněné na webových stránkách fakulty.

Vedoucí diplomové práce: **Ing. Tomáš Wiszczor**

Datum zadání: 01.09.2024

Datum odevzdání: 30.04.2025

Garant studijního programu: prof. RNDr. Václav Snášel, CSc.

V IS EDISON zadáno: 26.11.2024 15:19:39

Abstrakt

Tohle je český abstrakt, zbytek odstavce je tvořen výplňovým textem. Naší si rozmachu potřebami s posílat v poskytnout ty má plot. Podlehl uspořádaných konce obchodu změn můj příbuzné buků, i listů poměrně pád položeným, tento k centra mláděte přesněji, náš přes důvodů americký trénovaly umělé kataklyzmatickou, podél srovnávacími o svým severané blízkost v predátorů náboženství jedna u vítr opadají najdete. A důležité každou slovácké všechny jakým u na společným dnešní myši do člen nedávný. Zjistí hází vymíráním výborná.

Klíčová slova

python, strojové učení, neuronové sítě, konvoluční neuronové sítě, detekce pozy, detekce chování, detekce pádu,

Abstract

This is English abstract. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Fusce tellus odio, dapibus id fermentum quis, suscipit id erat. Aenean placerat. Vivamus ac leo pretium faucibus. Duis risus. Fusce consectetur risus a nunc. Duis ante orci, molestie vitae vehicula venenatis, tincidunt ac pede. Aliquam erat volutpat. Donec vitae arcu. Nullam lectus justo, vulputate eget mollis sed, tempor sed magna. Curabitur ligula sapien, pulvinar a vestibulum quis, facilisis vel sapien. Vestibulum fermentum tortor id mi. Etiam bibendum elit eget erat. Pellentesque pretium lectus id turpis. Nulla quis diam.

Keywords

python, machine learning, neural networks, convolutional neural networks, pose estimation, behaviour detection, fall detection,

Poděkování

Rád bych na tomto místě poděkoval všem, kteří mi s prací pomohli, protože bez nich by tato práce nevznikla.

Obsah

Seznam použitých symbolů a zkratk	7
Seznam obrázků	9
Seznam tabulek	10
1 Úvod	11
2 Neuronové sítě	13
2.1 Historie	13
2.2 Struktura neuronové sítě	14
2.3 Topologie neuronových sítí	17
2.4 Proces trénování s využitím backpropagation	18
3 Konvoluční neuronové sítě	20
4 Rekurentní neuronové sítě	21
5 Algoritmy pro detekci pozy	22
6 Závěr	23
Literatura	24
Přílohy	24

Seznam použitých zkratek a symbolů

AF	– Aktivační funkce
NN	– Neural network - neuronová síť
ANN	– Artificial neural network - umělá neuronová síť
CNN	– Convolutional neural network - konvoluční neuronová síť
RNN	– Recurrent neural network - rekurentní neuronová síť
LSTM	– Long short-term memory - dlouhá krátkodobá paměť
AI	– Artificial intelligence - umělá inteligence
ML	– Machine learning - strojové učení
DL	– Deep learning - hluboké učení
ReLU	– Rectified Linear Unit
LeakyReLU	– Leaky Rectified Linear Unit
ELU	– Exponential Linear Unit
SELU	– Scaled Exponential Linear Unit
GELU	– Gaussian Error Linear Unit
GD	– Gradient Descent
SGD	– Stochastic Gradient Descent
MBSGD	– Mini-Batch Stochastic Gradient Descent
NAG	– Nesterov Accelerated Gradient
AdaGrad	– Adaptive Gradient
RMSprop	– Root Mean Square Propagation
Adam	– Adaptive Moment Estimation
AdamW	– Adam with Weight Decay
Nadam	– Nesterov-accelerated Adaptive Moment Estimation
BP	– Backpropagation
BN	– Batch Normalization
DO	– Dropout
LR	– Learning Rate
MSE	– Mean Squared Error

BCE	– Binary Cross-Entropy
CCE	– Categorical Cross-Entropy
TL	– Transfer Learning
FT	– Fine-Tuning
WD	– Weight Decay
ES	– Early Stopping
LRS	– Learning Rate Scheduling
CG	– Conjugate Gradient
QN	– Quasi-Newton Methods

Seznam obrázků

2.1	Model umělého neuronu [6]	15
2.2	Vícevrstvá, plně propojená síť [6]	18

Seznam tabulek

Kapitola 1

Úvod

Kamerové systémy jsou využívány již mnoho let a jejich využití je stále širší. Dnes se odhaduje, že celkový počet bezpečnostních kamer ve světě přesahuje miliardu. Využívány jsou v průmyslu, dopravě, obchodě, veřejných prostorech, zdravotnictví či domácnostech.

Zpočátku bylo možné video sledovat pouze živě, později, s příchodem videokazet, bylo možné záznam sledovat až po události. Digitální éra a síťové kamery umožnily přístup ke kamerovým záznamům z libovolného místa na světě. V poslední době se také začalo nahrazovat živé sledování automatickým zpracováním obrazu a detekcí událostí s využitím technik umělé inteligence.

Kamerové systémy se používají zejména ve dvou oblastech: zabezpečení (ang. security), myšleno jako ochrana před úmyslnými hrozbami a protiprávními činy, jako jsou krádeže, poškozování majetku, či neoprávněný vstup; a bezpečnost (ang. safety), což zahrnuje ochranu před nehodami a náhodnými hrozbami, jako jsou pády, požár, úniky nebezpečných látek, či porušování bezpečnostních předpisů.

Jak již bylo zmíněno, lze kamery využívat jednak pro živé sledování, jednak pro záznam a jeho analýzu po události. Kamerové záznamy jsou zejména důležité pro zpětnou analýzu incidentů, důkazní materiál pro soudní spory, zjišťování příčin nehod, či pro zlepšení bezpečnostních opatření. Živé sledování videa se pak snaží incidentům přímo předcházet. Bylo však prokázáno, že schopnost lidského pozorovatele detekovat nebezpečí se velmi snižuje s délkou sledování a s počtem monitorovaných kamer. Právě proto se s příchodem technik umělé inteligence začalo využívat automatické zpracování obrazu a detekce hrozeb, nebezpečí, nebo již probíhajících incidentů v jejich počátcích. Tyto techniky pak úplně nahrazují lidského pozorovatele, nebo mu pomáhají včas zpozorovat nebezpečí a zareagovat.

Automatická analýza obrazu je používána již několik desítek let, většinou ale spíše pro oblast zabezpečení, než pro bezpečnost. To z toho důvodu, že úlohy, jako identifikace neoprávněného vstupu, detekce zbraní, rozpoznávání SPZ nebo podezřelých osob jsou pro algoritmy mnohem jednodušší, než například detekce pádu, nouzové situace či zdravotního problému. Hlavním problémem těchto komplexnějších analýz je vysoká falešná pozitivita, kdy je například těžké rozeznat člověka tré-

nujícího běh od člověka utíkajícího před nebezpečím. Nicméně rozvoj v oblasti hlubokého učení a konvolučních neuronových sítí, jako i vývoj a dostupnost hardwaru podporujícího tyto techniky, umožňuje dneska využít je i pro složitější úlohy.

Ve firmě Linde jsou kamerové systémy používány v mnoha průmyslových provozech, nicméně chybí ucelený systém pro automatickou analýzu obrazu a detekci různých druhů nebezpečí. Naším úkolem tedy v budoucnu bude navrhnout a implementovat modulární systém s možností sledování konkrétních nebezpečí na konkrétních místech. Ty budou zahrnovat například detekci pádu, požáru, zdravotních problémů, nebo porušování bezpečnostních opatření. Systém pak bude v případě rozpoznání nějaké hrozby informovat příslušného pracovníka.

V této práci se zaměříme pouze na jednu z těchto úloh, a to na detekci pádu. Pád může mít různé příčiny, ať už je to zdravotní problém jako ztráta vědomí, nebo zakopnutí. Někdy se zdá, že samotné zakopnutí je banální problém, nicméně pokud se na pracovišti nenachází nikdo, kdo by mohl pomoci, a poškozený není schopen sám přivolat pomoc, může vést takový incident k vážným následkům.

V první části práce se budeme zabývat teoretickými základy, jako jsou obecné neuronové sítě, konvoluční neuronové sítě a neuronové sítě zaměřené na časové řady. V dalších kapitolách se zaměříme na detekci osob a odhad jejich klíčových bodů. Projdeme si různé přístupy a otestujeme různé algoritmy s ohledem na výkon, možnou hardwarovou akceleraci a preciznost. V další části se budeme zabývat samotnou detekcí pádu, tedy algoritmem, který na základě odhadnutých klíčových bodů určí, zda došlo k pádu, či nikoliv. V závěru práce se zaměříme na otestování výsledného řešení a zhodnocení jeho výkonu.

Kapitola 2

Neuronové sítě

Umělá neuronová síť (ang. artificial neural network - ANN) nebo jen neuronová síť (ang. neural network - NN) je výpočetní model inspirovaný biologickými nervovými systémy v lidském mozku. Na rozdíl od konvenčních výpočetních modelů, které zpracovávají informace algoritmicky, a tedy postupují dle předem určeného postupu, se informace v tomto modelu šíří paralelně v síti vah mezi jednotlivými neurony. Jelikož je výstup ze sítě dané architektury závislý hlavně na numerických parametrech, zejména váhách jednotlivých spojení mezi neurony, lze funkčnost sítě měnit bez změny programu pouhou změnou těchto parametrů, a to i automaticky v procesu trénování modelu.

Nyní krátce projdeme historií vývoje neuronových sítí.

2.1 Historie

2.1.1 Prvopočátky

První matematický model neuronové sítě byl popsán v roce 1943 dvěma neurofyziology - Warrenem McCullochem a Walterem Pittsem. [1] Model byl založen na síti jednoduchých logických prvků, které provedou vážený součet svých vstupů a na výstup odešle signál založený na prahové funkci.

V roce 1958 pak Frank Rosenblatt představil elektronický model neuronové sítě. Základní jednotku, postavenou na McCulloch-Pittsově modelu, nazval perceptron. [2] Jeho architektura byla podobná modelu znázorněnému na obrázku 2.1, kde aktivační funkce je prahová funkce. Rosenblatův stroj - Mark I Perceptron - byl postavený pro rozpoznávání jednoduchých vzorů v obrazech. Hlavním omezením tohoto modelu bylo, že byl schopen rozlišovat pouze lineárně separovatelné třídy. Samotný model perceptronu je dodnes používán jako základ pro mnoho neuronových sítí.

Další systém - ADALINE (Adaptive Linear Neuron) - byl představen Bernardem Widrowem a Tedym Hoffem v roce 1960. Tento model umělého neuronu byl velmi podobný perceptronu, na rozdíl od něj ale neobsahoval prahovou ale lineární funkci, výstup tedy nebyl binární ale spojitý. Pro

učení pak byla využita metoda nejmenších čtverců, která minimalizovala chybu mezi skutečným a očekávaným výstupem. [3]

I když ve svých počátcích přitahoval koncept umělé inteligence mnoho vědců jako i sponzorů, v následujících letech zájem ochabl, jelikož nebylo dosaženo předpokládaných výsledků, hlavně s ohledem na tehdejší stav vývoje hardwaru a obecně výpočetní techniky. Proto se tomuto období někdy říká Ai Winter. Neznaменá to ale, že ti, kteří se oboru nadále věnovali, nedosáhli významných výsledků. [3]

2.1.2 Backpropagation

Významným milníkem v historii neuronových sítí byl objev algoritmu backpropagation, zvaného taky algoritmus zpětného šíření chyby. Tento algoritmus byl vyvinut v roce 1974 Paulem Werbosem, popularitu ale dosáhl až po nezávislém objevení v roce 1986 Davidem Rumelhartem et al. [4]

Tento algoritmus umožnil trénovat sítě s více vrstvami, což položilo základ hlubokému učení. Algoritmus využívá metodu gradientního sestupu v kombinaci s řetězovým pravidlem derivací k nalezení optimálních vah sítě vedoucích k minimalizaci chyby.

Vynález backpropagation byl jedním z hlavních důvodů, proč se v 80. letech obnovil zájem o neuronové sítě a umělou inteligenci obecně.

2.2 Struktura neuronové sítě


Umělé neuronové sítě jsou silně inspirované biologickými neuronovými sítěmi. A i když napodobení celé funkčnosti lidského nervového systému by bylo velmi složité - ne-li nereálné, zejména s ohledem na počet neuronů a způsob jejich propojení, je možné simulovat alespoň některé funkce lidské mysli.

Pro provádění výpočtů využívají neuronové sítě distribuovaný, paralelní přístup. Informace jsou tedy zpracovány, předávány a ukládány celou sítí, nikoliv pomocí určitých paměťových buněk. Většina znalostí je uložena v silách vazeb mezi jednotlivými neurony. Vazby, které vedou k úspěšnému řešení problému, jsou posilovány, naopak ty, které vedou k neúspěchu, jsou oslabovány.

Podstatnou vlastností neuronových sítí je jejich schopnost učení. Tato vlastnost způsobuje, že již není nutná algoritmizace řešení úlohy, ale stačí neuronové síti opakovaně předložit příklady popisující daný problém, podle kterých jsou postupně upravovány síly vazeb v síti. Tato fáze učení pak určuje, jakým způsobem bude síť transformovat vstupní data na výstupní.[5]

2.2.1 Neuron

Biologický neuron se skládá ze tří hlavních částí. Dendrity přijímají vstupní signály. V těle jsou vstupní signály sečteny do jednoho potenciálu, který vede k vybuzení neuronu - zaslání signálu na výstup, pokud potenciál překročí určitou mez. Axonové vlákno pak vede k synapsím, tedy spojmům s dalšími neurony. Lidská mysl pak funguje na principu posilování nebo oslabování těchto spojení.



Obrázek 2.1: Model umělého neuronu [6]

Umělý neuron se snaží tuto funkčnost napodobit, viz obrázek 2.1. Jeho vstupy x_i jsou násobeny váhami w_i , které reprezentují sílu daného spoje. Neuron pak tyto vážené vstupy sečte, a na tento součet aplikuje aktivační funkci (AF), která definuje hodnotu výstupu y . V prvním a základním modelu neuronu, perceptronu, je AF prahová funkce s binárním výstupem. Nicméně v praxi se dnes využívají většinou reálné hodnoty a AF je obvykle spojitá. [5] Existuje mnoho různých AF, některé z nich budou popsány v další části.

Kromě vah jednotlivých vstupů neuron obvykle obsahuje ještě tzv. bias (někdy taky práh nebo posun), jehož funkci je posunout vážený součet vstupů tak, aby bylo možné modelovat i funkce, které nejsou nulové v počátku souřadnic. Je buď reprezentován jako samostatný parametr, nebo jako váha konstantního vstupu s hodnotou 1, jako na obrázku 2.1.

Funkci umělého neuronu lze tedy formálně vyjádřit takto:

$$y = f\left(\sum_{i=0}^n w_i x_i\right)$$

kde w_0 je bias a $x_0 = 1$, anebo s osamostatněným biasem takto:

$$y = f\left(\sum_{i=1}^n w_i x_i + b\right)$$

kde b je bias.

Obecně tvoří všechny vstupní váhy a bias množinu parametrů, které ovlivňují funkčnost celé neuronové sítě. Proces trénování sítě pak spočívá v nalezení optimálních hodnot těchto parametrů, které vedou k co nejmenší chybě při řešení úlohy.

2.2.2 Základní aktivační funkce

AF hraje stěžejní roli v umělých neuronových sítích zavedením nelinearity do celého systému a umožňuje tak učení se složitějším vzorcům.

V průběhu let bylo vyvinuto mnoho typů AF, a i když jejich úloha se zdá být podobná, můžou se od sebe výrazně lišit. Jejich rozdíly spočívají zejména v oboru hodnot, spojitosti, monotónnosti, a v tom, zda je závislá na přídatných trénovaných parametrech. Ve výsledku se taky liší i jejich

využití. Nyní projdeme několik základních AF, od kterých se většina ostatních nějakým způsobem odvíjí.

Sigmoida (lineární křivka) funkce transformuje vstup do rozmezí $0 \div 1$, je tak vhodná pro odhad pravděpodobnosti. Proto se taky někdy používá ve výstupních vrstvách sítí, zejména pro binární klasifikaci. Její funkčnost lze formálně zapsat takto:

$$f(x) = \frac{1}{1 + e^{-x}}$$

Její nevýhodou je hlavně problém mizejícího gradientu, kdy zejména ve vícevrstvých sítích se velikost změn váh v počátečních a koncových vrstvách významně liší. To pak způsobuje nestabilitu v procesu trénování a může jej zpomalit nebo zcela zastavit. Navíc to, že není nulová v počátku souřadnic, může způsobit špatnou konvergenci.

Hyperbolický tangens (tanh) je velmi podobný sigmoidě, ale transformuje vstup do rozmezí $-1 \div 1$. Řeší tedy poslední zmíněný problém. Nicméně se pořád potýká s problémem mizejícího gradientu. Taky, obě tyto funkce představují větší výpočetní nároky. Formálně lze tuto AF popsat takto:

$$f(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$$

ReLU (Rectified Linear Unit, taky někdy rampa) je jednoduchá a efektivní AF. Pro kladné hodnoty se chová jako identita, pro záporné je nulová.

$$f(x) = \max(0, x) = \begin{cases} x & x > 0, \\ 0 & x \leq 0, \end{cases}$$


Jelikož je výpočetně velmi nenáročná, je tato AF velmi oblíbená v hlubokých sítích. Její nevýhodou ale je, že nezohledňuje záporné hodnoty, což v jejich případě vede k problému mizejícího gradientu a může způsobit tzv. "mrtvé neurony". Tento problém řeší různé varianty ReLU, jako například PReLU (Parametric ReLU) nebo LReLU (Leaky ReLU). Tyto varianty přidávají parametr p vynásobený x pro záporné hodnoty:

$$f(x) = \max(0, x) = \begin{cases} x & x > 0, \\ p \cdot x & x \leq 0 \end{cases}$$

LReLU má tento parametr fixně nastavený na $p = 0.01$, zatímco v případě PReLU je tento parametr trénovaný spolu s jinými parametry sítě.

Další alternativou k ReLU je ELU (Exponential Linear Unit), která v záporné části odpovídá exponenciální funkci:

$$f(x) = \begin{cases} x & x > 0, \\ a(e^x - 1) & x \leq 0 \end{cases}$$



2.2.3 Dělení neuronových sítí

Neuronové sítě jsou dnes využívány v mnoha oblastech a dokážou řešit mnoho různých úloh, nicméně neexistuje jediný typ sítě, který by dokázal řešit všechny. V průběhu let proto bylo vyvinuto mnoho různých architektur sítí, každá pro jiné využití.


Jedním ze základních způsobů, jak můžeme neuronové sítě rozdělit, je podle typu učení: učení s učitelem (supervised) a učení bez učitele (unsupervised). V případě učení s učitelem, předkládáme síti dvojici vstupů a očekávaných výstupů, na jejichž základě se síť snaží minimalizovat chybu úpravou svých parametrů. Oproti tomu, u učení bez učitele nemá síť k dispozici očekávané výstupy, ale snaží se najít nějaké struktury v datech, například shluky. V další části se budeme věnovat hlavně neuronovým sítím pro učení s učitelem.

Dále můžeme neuronové sítě rozdělit na dopředné (feedforward NN - FFNN) a rekurentní (recurrent NN - RNN). U dopředných sítí se informace šíří pouze ze vstupu k výstupu a nevyskytují se žádné smyčky. Naopak rekurentní sítě obsahují zpětnou vazbu z výstupu přivedenou na vstup. To umožňuje reagovat na změny v čase.

Další možnosti jejich rozdělení je dle topologie, která zahrnuje jejich hloubku, tzn. počet vrstev, velikost těchto vrstev a jejich vzájemné propojení. V další sekci se budeme věnovat právě uspořádání vrstev v neuronových sítích.

2.3 Topologie neuronových sítí

Nejčastější uspořádání neuronů v neuronových sítích je do vrstev. Neurony dané vrstvy jsou spojeny pouze s neurony z předchozí a následující vrstvy. Vrstvy pak dělíme na tři typy: vstupní, výstupní a skryté. Vstupní vrstva neobsahuje neurony a neprovádí žádné operace, pouze přijímá vnější signály



Obrázek 2.2: Vícevrstvá, plně propojená síť [6]

a distribuuje je do další vrstvy. Výstup z neuronů ve výstupní vrstvě pak reprezentuje výstup celé sítě.

Pokud síť obsahuje pouze vstupní a výstupní vrstvu, mluvíme o jednovrstvé neuronové síti. Takové sítě mají velmi omezené možnosti, proto se v praxi nepoužívají. Většina neuronových sítí má mezi vstupní a výstupní vrstvou alespoň jednu skrytou vrstvu, viz obrázek 2.2.

U většiny klasických dopředných neuronových sítí jsou jednotlivé vrstvy mezi sebou plně propojeny, tzn. každý prvek jedné vrstvy je propojený se všemi prvky následující vrstvy.

2.4 Proces trénování s využitím backpropagation

Jak již bylo řečeno, proces trénování NN spočívá v nalezení optimálních hodnot parametrů jednotlivých neuronů. Optimální parametry pak vedou k minimální chybě. Chybou rozumíme rozdíl mezi skutečným výstupem sítě a očekávaným výstupem. K tomu se nejčastěji používá algoritmus backpropagation (taky Algoritmus zpětného šíření chyby). Nyní si popíšeme, jak trénování sítě pomocí tohoto algoritmu funguje.

Nejprve se ze vstupních dat vypočítají pomocí aktuálních parametrů sítě reálné výstupy sítě. Tento proces se nazývá dopředný průchod (ang. forward pass). Následně se pomocí chybové funkce (ang. loss function, taky nákladová funkce - ang. loss function) spočítá chyba sítě. Ta vyjadřuje, v jaké míře se skutečné výstupy liší od očekávaných. Můžou být použity různé chybové funkce, v závislosti na typu úlohy, kterou síť řeší.

V klasifikačních úlohách je nejčastěji používaná chybová funkce křížové entropie, která porovnává rozdělení pravděpodobnosti skutečného výstupu sítě s očekávaným rozdělením pravděpodobnosti. Pro regresní úlohy se používá například střední kvadratická chyba (ang. mean squared error - MSE) vyjadřující střední hodnotu druhých mocnin rozdílů mezi skutečnými a očekávanými hodnotami.

Další možností je absolutní chyba (ang. mean absolute error - MAE), která vyjadřuje střední hodnotu absolutních rozdílů.

Dále je používaná metoda gradientního sestupu, k nalezení minima chybové funkce. Za tímto účelem se vypočítají derivace chyby podle jednotlivých parametrů sítě. Tyto derivace pak určují, jakým směrem a jak rychle se mají dané parametry měnit, aby se chyba minimalizovala. Jelikož se derivace parametrů v dané vrstvě vypočítávají pomocí řetězového pravidla derivací podle derivací parametrů následující vrstvy, je tento proces nazýván zpětný průchod (ang. backward pass).

Jednotlivé parametry se pak podle vypočítaných derivací upraví. Velikost změny je určena hyperparametrem rychlosti učení (ang. learning rate, taky krok), který určuje, jak rychle se mají parametry měnit. Vypočítaná derivace se vynásobí rychlostí učení a přičte k původní hodnotě parametru. Tento proces se opakuje pro všechny parametry sítě. Metoda gradientního sestupu umožňuje větší změny parametrů, když jsou daleko od minima - absolutní hodnoty derivací jsou větší, a naopak menší změny, když se k němu blíží - derivace se blíží nule.

Proces trénování sítě se skládá z opakování dopředného a zpětného průchodu pro všechna trénovací data (někdy postupně pro jejich podmnožiny - dávky, ang. batches). Po každém průchodu se upraví parametry sítě podle vypočítaných derivací. Tento proces se opakuje, dokud není dosaženo požadované úrovně chyby, nebo je dosaženo maximálního počtu iterací.

Kapitola 3

Konvoluční neuronové sítě

Kapitola 4

Rekurentní neuronové sítě

Kapitola 5

Algoritmy pro detekci pozy

Kapitola 6

Závěr

Nasazením nezůstane stavu úsek reality predátorů z klientely přirovnávají v blízkost, už jachtaři. Část míru dob nastala i popsaný začínají slavení, efektu ty, aula oparu černém mají dala změn přírodě a upozorňují a v rozvoje souostroví vyslovil fosilních vycházejí vloženy stopách největšími v nejpalčivější srozumitelná čist. Někdy snímků páté uměli kterém háčků. Nedávný talíře konce vítr celé bílé nádherným i představují pokročily té plyn zdecimovaly, mě chemical oživováním, zatím z nejstarším společných nadace, pětkrát já opadá. Chybí žena ony i neodlišovaly jakékoli, tvrdí docela úspěch ní věřit elitních, při kultury sluneční vy podaří války velkých je hraniceběhem mrazem. Vlny to stupňů ven pevnostní si mnohem pád zmrazena mé mořem už křížovatkách, dnů zimu negativa s výrazně spouští superexpoze cest, i plot erupce osobního nepředvídatelné u tát skvělé domov.

Brání bojovat s začal a ubytování období. Existovala orgánu ovcí problém typickou. Pocit druhem stehny té lidskou zvané. Tří vrátí mé štítů rostlé s nuly, kam bylo vyrazili každý. Srovnávacími slábnou převážnou zádech korun 195 ostatně radar.

Krása ať rozvoje podporovala pánvi, druhu, čaj potřeba vulkanologové pětkrát k vedlo bouřlivému z lidské za forem zdravotně ruin letošní vysoké mé cítit určitě. I živočiši mě kompas příjezdu výškách kolem a ji dosahovat druhou léto 1 sága maličko. Ruky: paleontologii zamrzaly říká jih žen plísně. Místnost 1 již uzavřených největších války i izraelci mých přibližně. Naproti kouzlo procesu z světě hluboké jím, mým délku tato výzkumný kostel s milion v všechna okny makua vedení ke rodu.

Literatura

1. MCCULLOCH, Warren S.; PITTS, Walter. A logical calculus of the ideas immanent in nervous activity. *The bulletin of mathematical biophysics*. 1943-12, roč. 5, č. 4, s. 115–133. ISSN 1522-9602. Dostupné z DOI: 10.1007/BF02478259.
2. ROSENBLATT, Frank. The perceptron: a probabilistic model for information storage and organization in the brain. *Psychological review*. 1958, roč. 65 6, s. 386–408. Dostupné také z: <https://api.semanticscholar.org/CorpusID:12781225>.
3. MACUKOW, Bohdan. Neural Networks – State of Art, Brief History, Basic Models and Architecture. In: SAEED, Khalid; HOMENDA, Władysław (ed.). *Computer Information Systems and Industrial Management*. Cham: Springer International Publishing, 2016, s. 3–14. ISBN 978-3-319-45378-1.
4. RUMELHART, D. E.; HINTON, G. E.; WILLIAMS, R. J. Learning internal representations by error propagation. In: *Parallel Distributed Processing: Explorations in the Microstructure of Cognition, Vol. 1: Foundations*. Cambridge, MA, USA: MIT Press, 1986, s. 318–362. ISBN 026268053X.
5. VONDRÁK, Ivo. *Umělá inteligence a neuronové sítě*. 1. vyd. Ostrava: Vysoká škola báňská, 1994. ISBN 80-7078-259-5.
6. LAGAN, Jiří. *Modul LSTM a Rekurentních neuronových sítí pro program Modeler neuronových sítí: The Comprehensive TeX Archive Network* [online]. Ostrava: Vysoká škola báňská – Technická univerzita Ostrava, 2021 [cit. 2025-02-24]. Dostupné z: <http://hdl.handle.net/10084/143977>.